Capitolul 5

Segmentarea orientată pe regiuni

Segmentarea se referă la descompunerea unei scene (imagini) în părţile sale constituente (componente, elemente) [33], [68], [8] sau extragerea din scenă a componentei de interes pentru aplicaţie. Segmentarea este în general o problemă ambiguă, atâta timp cât există mai multe soluţii corecte de segmentare ale aceleiaşi imagini (cu excepţia unor aplicaţii specifice din domenii precis delimitate, precum defectoscopia sau recunoaşterea optică a caracterelor tipărite – OCR (*Optical Character Recognition*)). Din punct de vedere matematic putem exprima segmentarea unei imagini f ca o partiţionare a suportului spaţial al acesteia într-un ansamblu de K mulţimi f_i disjuncte, nevide, ce satisfac individual un anume criteriu de definiţie C, criteriu ce nu mai este respectat de orice pereche de mulţimi (f_i, f_j):

$$f = \bigcup_{i=1}^{K} f_i,\ f_i \neq \emptyset,\ \forall i \tag{5.1a}$$

$$f_i \bigcap f_j = \emptyset,\ \forall i \neq j \tag{5.1b}$$

$$\mathsf{C}\left(f_i\right) = \text{ADEVĂRAT},\ \forall i \tag{5.1c}$$

$$\mathsf{C}\left(f_i \bigcup f_j\right) = \text{FALS}, \forall i \neq j \tag{5.1d}$$

În general, criteriul C de definiţie a mulţimilor (regiunilor) ce se doresc identificate prin segmentare impune ca acestea să fie conexe şi să fie uniforme din punctul de vedere al unui set de parametri caracteristici (chiar valoarea pixelului sau caracteristici derivate din valorile pixelilor). În covârşitoarea majoritate a aplicaţiilor, criteriul de definiţie al regiunilor este un criteriu de uniformitate relativ doar la valorile pixelilor ce compun regiunea; astfel, obiectele (regiunile) ce se doresc identificate sunt caracterizate de intervale înguste de variaţie a nivelelor de gri. După cum criteriul de definiţie C impune sau nu conexitatea mulţimilor f_i rezultate, numărul de mulţimi K va reprezenta numărul de obiecte individuale, respectiv numărul de tipuri de obiecte din imagine.

În lipsa unor criterii impuse de aplicaţii particulare, calitatea segmentării poate fi apreciată în mod generic prin compararea numărului de obiecte rezultate în urma segmentării cu numărul real de obiecte din imagine. După cum numărul real de obiecte este mai mare, respectiv mai mic decât numărul de obiecte rezultate prin segmentare, vom vorbi de erori

de suprasegmentare, respectiv de subsegmentare. Presupunând că marginile obiectelor sunt identificate relativ corect, suprasegmentarea înseamnă că un obiect a fost descompus (separat, spart) în mod artificial şi eronat în mai multe componente. Subsegmentarea înseamnă că obiecte reale, diferite, dar învecinate spaţial au fost reunite în mod eronat prin segmentare într-o singură componentă.

Este greu de introdus un indice numeric obiectiv universal de apreciere a calităţii segmentării; formulele propuse recent de Liu [36] (5.2) şi Borsotti [6] (5.3) sunt deduse în ipoteza că regiunile sunt caracterizate de uniformitatea nivelului de gri şi că este mai importantă identificarea corectă a regiunilor mari. Indicii de calitate propuşi au forma:

$$Q = \frac{1}{1000N}\sqrt{K}\sum_{i=1}^{K}\frac{\sigma_i^2}{\sqrt{n_i}} \tag{5.2}$$

$$Q = \frac{1}{1000N}\sqrt{K}\sum_{i=1}^{K}\left(\frac{\sigma_i^2}{\log n_i} + \left(\frac{Nb(n_i))}{n_i}\right)^2\right). \tag{5.3}$$

În expresiile de mai sus, N este numărul de pixeli din imagine, K este numărul de regiuni obţinute prin segmentare, σ_i^2 este varianţa nivelelor de gri a celor n_i pixeli din regiunea f_i, iar $Nb(n_i)$ este numărul de regiuni ce au acelaşi număr de pixeli, n_i.

Principala distincţie între diferitele tehnici de segmentare orientată pe regiuni se referă la domeniul primar de căutare (adică domeniul în care se încearcă separarea pixelilor din imagine după tipurile de obiecte căutate): domeniul spaţial şi domeniul valorilor.

Segmentarea în domeniul spaţial foloseşte iniţial (în mod fundamental) informaţia de poziţie a pixelilor. Obiectele (regiunile) identificate prin segmentare sunt fundamental conexe, îndeplinirea criteriului de definiţie acţionând ca un criteriu de limitare. Creşterea regiunilor şi etichetarea imaginilor binare sunt asemenea metode de segmentare. În cazul etichetării imaginilor binare, uniformitatea valorilor este evidentă pentru orice componentă, mai trebuind a fi asigurată conexitatea.

Segmentarea în domeniul (spaţiul) valorilor foloseşte numai informaţia de valoare a pixelilor, fără a considera şi distribuţia spaţială a acestor valori. Ca rezultat al acestei partiţionări bazate numai pe valoare, mulţimile-obiect identificate nu sunt conexe (ceea ce poate fi exprimat prin aceea că, la nivelul mulţimilor identificate prin segmentare, criteriul de definiţie C nu include ipoteza de conexitate). Întotdeauna este necesar ca segmentarea în domeniul valorilor să fie urmată de o etichetare a imaginilor binare ce corespund regiunilor de interes.

5.1 Segmentarea în suportul imaginii

Esenţa algoritmilor de segmentare în suportul imaginii este identificarea pixelilor ce formează un acelaşi obiect prin detecţia adiacenţelor dintre aceştia şi asocierea unei etichete unice tuturor punctelor aceluiaşi obiect. Adiacenţa (vecinătatea) este deci conceptul fundamental pe baza căruia sunt identificate obiectele. Adiacenţa este determinată de tipul de conexitate adoptat; în cazul imaginilor eşantionate pe o reţea pătrată sunt uzuale modelele de conexitate de tip V_4 sau de tip V_8. Pentru o conexitate de tip V_4 fiecare

pixel al imaginii are patru vecini (ce formează ceea ce se numeşte vecinătatea imediată a punctului). Vecinătatea imediată a punctului de coordonate (l, c) este mulţimea $V_4(l, c) = \{(l-1, c), (l+1, c), (l, c-1), (l, c+1)\}$ şi este reprezentată în figura 5.1 a). Pentru o conexitate de tip V_8 fiecare pixel al imaginii are opt vecini (ce formează ceea ce se numeşte vecinătatea extinsă a punctului). Vecinătatea extinsă a punctului de coordonate (l, c) este mulţimea $V_8(l, c) = V_4(l, c) \bigcup \{(l-1, c-1), (l+1, c-1), (l-1, c+1), (l+1, c+1)\}$ şi este reprezentată în figura 5.1 b). Un drum între două puncte ale imaginii este o secvenţă

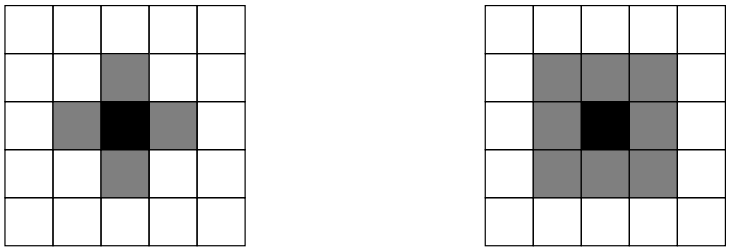


Figura 5.1: *a) Vecinătatea imediată (V_4) şi b) vecinătatea extinsă (V_8) a unui pixel.*

ordonată de puncte ale imaginii, vecine două câte două (relativ la un anumit tip de conexitate, V_4 sau V_8), care are drept capete punctele considerate.

5.1.1 Creşterea regiunilor

Principiul pe care se bazează creşterea regiunilor este simplu: se aleg în imagine puncte reprezentative pentru fiecare obiect individual şi/sau categorie de obiecte, în jurul cărora are loc un proces de aglomerare a pixelilor vecini, ce au aceleaşi proprietăţi (în particular acelaşi nivel de gri sau aceeaşi culoare). În urma acestui proces de aglomerare (adăugare de puncte) se obţin zone (regiuni) de pixeli cu aceleaşi caracteristici, deci obiecte individuale. Procesul se opreşte în momentul în care toate punctele imaginii au fost alocate câte unei regiuni. Evident, metoda astfel descrisă pe scurt, are două etape esenţiale: alegerea punctelor de start (puncte iniţiale), numite germeni sau seminţe, şi creşterea propriu-zisă a regiunilor [68], [8].

Alegerea germenilor

Este evident că numărul final de regiuni rezultate este egal cu numărul de germeni iniţiali. În principiu, este de dorit ca fiecare obiect individual aflat în imagine să fie marcat de câte un germene unic. Dacă în interiorul unui aceluiaşi obiect se găsesc mai mulţi germeni, pentru fiecare dintre ei va fi crescută o regiune, ceea ce face ca obiectul iniţial să fie împărţit artificial prin segmentare în mai multe regiuni. Parţial, acest neajuns se poate corecta printr-o etapă ce urmează creşterii regiunilor, şi anume fuziunea regiunilor adiacente ce au proprietăţi asemănătoare. Dacă în interiorul unui obiect nu este ales nici un germene, obiectul respectiv va fi înglobat de regiunile ce cresc pornind de la germeni din vecinătatea sa spaţială; astfel, respectivul obiect nu apare ca o regiune distinctă şi este pierdut, rezultând o eroare gravă de segmentare.

Pentru a preveni efectul unor neuniformităţi de iluminare pe suprafaţa imaginii, aceasta este împărţită în ferestre nesuprapuse; în fiecare astfel de fereastră se alege un număr de germeni, al căror plasament spaţial este aleator (germenii se distribuie uniform pe suprafaţa ferestrelor şi a imaginii). Germenii se aleg astfel încât nivelul lor de gri să fie reprezentativ pentru obiectele prezente local (deci nivelul de gri al germenilor trebuie să corespundă unor maxime ale histogramei locale) şi plasamentul lor spaţial să se facă în interiorul regiunilor şi nu pe frontiera acestora (verificarea se poate face pe baza calculului unui operator derivativ local, ca de exemplu laplacianul (definit în 3.1 sau în (6.24)).

O verificare suplimentară încearcă să prevină o eventuală suprasegmentare (deci împărţirea artificială a unui acelaşi obiect în mai multe regiuni), eliminând germenii plasaţi în interiorul aceluiaşi obiect. Verificarea se face pe baza calculului variaţiei nivelelor de gri de-a lungul drumurilor arbitrare ce unesc perechi de germeni. Dacă există măcar o cale ce uneşte doi germeni de-a lungul căreia nivelul de gri nu variază semnificativ, se consideră că cei doi germeni sunt plasaţi în interiorul unei zone de nivele de gri uniforme, deci în interiorul unui aceluiaşi obiect. În aceste condiţii unul dintre cei doi germeni ai perechii este eliminat, deoarece este redundant. Dacă de-a lungul tuturor căilor ce unesc perechea de germeni nivelul de gri variază semnificativ, se consideră că cei doi germeni sunt plasaţi în interiorul unor obiecte diferite (deoarece căile ce unesc germenii traversează regiuni de frontieră). În practică, examinarea tuturor drumurilor (căilor) ce unesc perechi de germeni este costisitoare din punctul de vedere al timpului de calcul, de aceea se verifică doar căile formate din segmente verticale şi orizontale de lungime maximă, şi eventual, calea reprezentată de segmentul dreapta ce uneşte cele două puncte, după cum este exemplificat şi în figura 5.2.

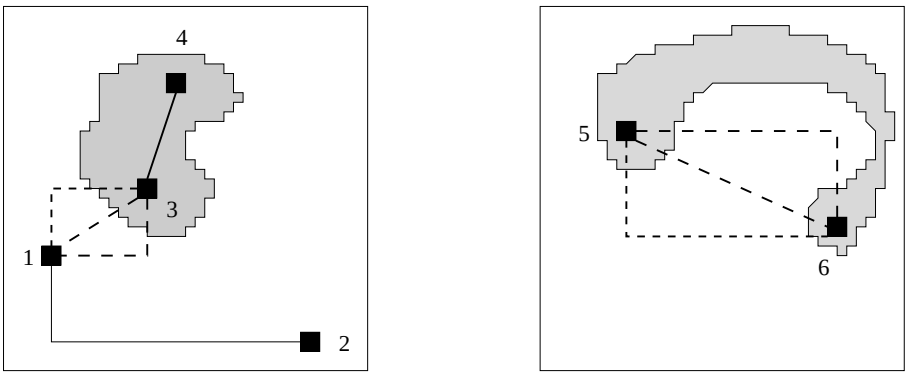


Figura 5.2: *Reducerea numărului de germeni: germenii 1 şi 2 sunt uniţi de o cale cu segmente paralele cu orizontala şi verticala de intensitate constantă, deci sunt redundanţi; germenii 3 şi 4 sunt uniţi de o cale dreaptă de aceeşi intensitate, deci sunt redundanţi; orice cale ce uneşte germenii 1 şi 3 are o diferenţă mare de intensitate. Deşi germenii 5 şi 6 sunt redundanţi, verificarea simplificată a drumurilor ce îi unesc conduce la păstrarea (falsă) a ambilor germeni, ceea ce va duce la împărţirea obiectului în două regiuni.*

Reprezentarea numerică a conceptelor de variaţie semnificativă a nivelelor de gri de-a lungul unei căi sau în jurul unui punct necesită definirea unor praguri de comparaţie, a căror alegere se face pe baza condiţiilor particulare din imagine şi a experienţei utilizatorului. Alternativa la acest proces complicat de plasare automată a germenilor este plasarea manuală, într-un proces de segmentare interactivă.

Creşterea propriu-zisă

Pornind de la germenii aleşi, regiunile sunt obţinute printr-un proces de creştere aproape simultană, începută de la aceştia, până când toţi pixelii imaginii sunt repartizaţi unei regiuni. Cvasi-simultaneitatea creşterii poate fi realizată cu un algoritm serial, prin alocarea pixelilor ce sunt adiacenţi (vecini) zonelor deja segmentate. Această alocare trebuie să ţină seama de criteriul ca regiunile crescute să fie uniforme: nivelul de gri al pixelului ce se adaugă nu trebuie să difere cu mai mult de un prag prestabilit faţă de nivelul de gri al germenului regiunii la care se alocă. În acelaşi timp, la o singură trecere, numărul de puncte ce se adaugă unei regiuni nu poate depăşi un număr prestabilit (condiţie ce încearcă să asigure creşterea relativ uniformă şi izotropă a tuturor regiunilor). Dacă adăugarea de noi pixeli se blochează (criteriul de uniformitate nu mai este respectat), diferenţa maxim admisă pentru nivelul de gri poate fi crescută în etape, până la alocarea tuturor pixelilor imaginii.

Alegerea pragului (a diferenţei maxim admise de nivele de gri) dintre pixelii ce se adaugă unei regiuni şi germene este o problemă ce nu are o soluţie universală: diferenţa maxim admisă poate varia de la o imagine la alta, şi chiar ar putea fi diferită de la o regiune la alta a aceleiaşi imagini. Rezultatul creşterii regiunilor depinde în mod esenţial de alegerea corespunzătoare a acestui parametru, după cum arată şi exemplul din figura 5.3.

Avantajele pe care le are tehnica de creştere a regiunilor sunt acelea că nu mai este necesară nici o informaţie privind conţinutul imaginii, regiunile crescute sunt conexe, nu există puncte neetichetate (nealocate vreunei regiuni) şi poziţia frontierelor dintre diferitele regiuni corespunde poziţiei frontierelor percepute subiectiv în imagine. Figura 5.3 prezintă un exemplu de segmentare a unui obiect dintr-o imagine prin creşterea regiunilor.

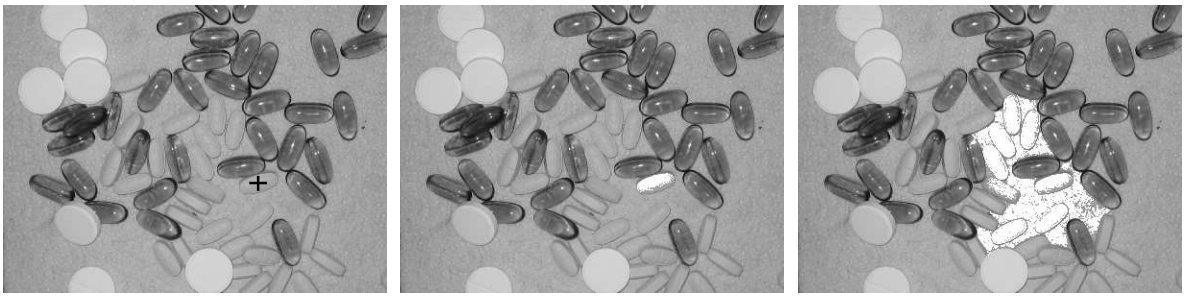


Figura 5.3: *Exemplu de creşterea regiunilor: în imaginea iniţială (din stânga) a fost crescută o regiune pornind de la germenele situat în poziţia (185,270) având nivelul de gri 189 (marcat în imagine cu o cruce neagră). Toleranţa maxim admisă a pixelilor din regiune faţă de germene este de 10. Regiunea crescută (reprezentată în alb pe imaginea centrală) se compune din 387 de pixeli şi corespunde destul de bine (cu excepţia unor mici puncte) cu obiectul din imagine ce s-a dorit extras. Relaxarea parametrului de toleranţă la 15 conduce la creşterea unei regiuni de 8536 pixeli (reprezentată în alb pe imaginea din dreapta), ce depăşeşte frontierele obiectului căutat.*

5.1.2 Etichetarea imaginilor binare

Imaginile binare sunt definite de doar două valori posibile pe care le pot lua punctele acestora: 0 şi 1. În mod convenţional se consideră că valoarea 1 corespunde punctelor-obiect (puncte de interes) din imagine, în timp ce valoarea 0 defineşte punctele fundalului (sau fondului imaginii). Etichetarea imaginilor binare are ca obiectiv identificarea şi separarea obiectelor individuale din imagine, deci marcarea tuturor punctelor ce aparţin unui anumit obiect cu o etichetă unică, diferită de etichetele celorlalte obiecte prezente. Fiecare obiect individual este o componentă conexă distinctă.

Etichetarea secvenţială iterativă

Etichetarea secvenţială iterativă [12] este cea mai simplă metodă de etichetare. Această metodă se compune din mai multe perechi de baleiaje succesive ale imaginii, care se încheie în momentul stabilirii etichetelor definitive ale obiectelor. Fiecare pereche de baleiaje se compune dintr-un baleiaj direct (în ordinea normală de parcurgere a unei imagini, deci pe linii, de la stânga la dreapta şi de sus în jos) şi un baleiaj invers (pornind din colţul din dreapta jos al imaginii, o parcurgere pe linii de la dreapta la stânga şi de jos în sus). La fiecare trecere prin imagine (baleiaj), pentru punctele de tip obiect, se execută o aceeaşi structură algoritmică simplă: dacă punctul curent are predecesori (în ordinea de baleiaj curentă) deja etichetaţi, atunci punctul curent capătă o etichetă identică cu eticheta minimă [1] a predecesorilor săi; dacă nu are predecesori deja etichetaţi, atunci i se atribuie o nouă etichetă (dacă baleiajul curent este primul baleiaj direct executat) sau eticheta sa rămâne neschimbată (dacă baleiajul curent nu este primul baleiaj executat). Etichetele noi se obţin prin incrementarea cu 1 a etichetei maxime existente. Prima etichetă are valoarea 1. Algoritmul se încheie atunci când după o pereche de baleiaje (direct şi invers), etichetele nu se mai modifică. Un pseudocod ce implementează algoritmul descris este prezentat în tabelul 5.1.

Predecesorii unui punct sunt pixelii imaginii, din vecinătatea extinsă sau imediată a punctului considerat, ce au fost deja parcurşi ("vizitaţi") în baleiajul curent. Astfel, pentru baleiajul direct, predecesorii punctului de coordonate (l, c), în conexitate V_4 sunt (vezi figura 5.4 a)) $Ant_{V_4}(l, c) = \{(l-1, c), (l, c-1)\}$, iar în conexitate V_8 sunt $Ant_{V_8}(l, c) = \{(l-1, c-1), (l-1, c), (l-1, c+1), (l, c-1)\}$. Pentru baleiajul invers, predecesorii punctului de coordonate (l, c), în conexitate V_4 sunt $Ant_{V_4}(l, c) = \{(l+1, c), (l, c+1)\}$, iar în conexitate V_8 sunt (vezi figura 5.4 b)) $Ant_{V_8}(l, c) = \{(l+1, c+1), (l+1, c), (l+1, c-1), (l, c+1)\}$.

Numărul de iteraţii necesar pentru etichetarea unei imagini este variabil şi depinde de conţinutul acesteia. În cazul în care toate obiectele din imagine sunt convexe, o singură pereche de baleiaje este suficientă pentru a eticheta corespunzător imaginea. Dacă

[1] Acesta presupune faptul că etichetele sunt numerice, cel puţin pentru execuţia algoritmului. Etichete oarecari (şiruri de simboluri) se pot obţine transformând, printr-un tabel de corespondenţă, etichetele numerice din imaginea deja etichetată.

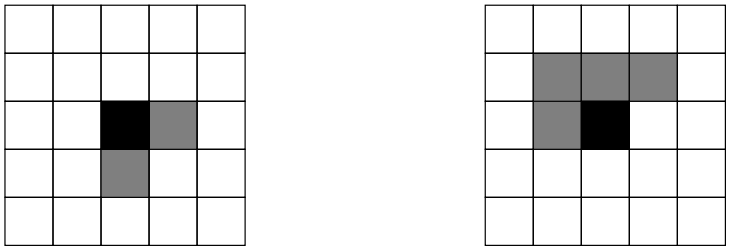


Figura 5.4: *Predecesorii unui pixel, în baleiaj invers, cu vecinătate V_4 b) Predecesorii unui pixel, în baleiaj direct, cu vecinătate V_8.*

repetă
baleiaj direct:
  dacă punctul curent este punct de obiect, **atunci**
    dacă punctul curent are predecesori etichetaţi, **atunci**
      punctul curent ia eticheta minimă a predecesorilor
    altfel
      dacă acesta este primul baleiaj direct, **atunci**
        punctul curent ia o etichetă nouă
baleiaj invers:
  dacă punctul curent este punct de obiect, **atunci**
    dacă punctul curent are predecesori etichetaţi, **atunci**
      punctul curent ia eticheta minimă a predecesorilor
până când etichetele nu se mai modifică

Tabela 5.1: *Pseudocodul corespunzător algoritmului de etichetare secvenţială iterativă.*

imaginea conţine obiecte concave (obiecte cu găuri, concavităţi de frontieră), numărul de treceri prin imagine până la stabilizarea etichetelor nu mai poate fi prezis şi creşte odată cu creşterea complexităţii obiectelor.

Etichetarea cu tabel de corespondenţă între etichete

Algoritmul anterior, pur secvenţial, nu necesită ca variabile de intrare sau de lucru decât imaginea binară iniţială. Aparenta simplitate este însă umbrită de timpul de rulare dependent de conţinutul imaginii etichetate. Algoritmul de etichetare cu corespondenţă între etichete foloseşte o informaţie ce apare în timpul baleiajului secvenţial, şi anume eventualele corespondenţe dintre etichete, detectate de algoritmul de etichetare secvenţială iterativă în momentul testării etichetelor predecesorilor punctului curent. Eticheta punctului curent îşi modifică valoarea (ia valoarea etichetei unui vecin) dacă punctul curent este un punct ce face conexiunea între două regiuni ale unui acelaşi obiect, etichetate însă diferit. În mod normal, modificarea valorii unei etichete duce la reetichetarea tuturor punctelor imaginii, dar aceasta informaţie poate fi înscrisă într-un tabel de corespondenţe a cărui utilizare va reduce numărul de baleiaje necesar la numai două (un baleiaj direct pentru iniţializarea etichetelor şi scrierea tabelului de corespondenţă şi un al doilea baleiaj direct pentru calcularea etichetelor finale din tabelul de corespondenţă), indiferent de conţinutul imaginii [12].

Fie T tabelul de corespondenţă între etichete; la pornirea algoritmului, fiecare intrare a tabelului este iniţializată cu valoarea indicelui acesteia ($T(j) = j$). Actualizarea tabelului se face în două situaţii:
- dacă punctul curent nu are nici un predecesor punct de obiect, atunci acesta trebuie să primească o nouă etichetă, care se adaugă la "coada" tabelului de echivalenţă ca $T(j_{\max}) = j_{\max}$;
- dacă punctul curent are toţi predecesorii etichetaţi şi va primi eticheta minimă a acestora, atunci în tabelul de corespondenţă trebuie înscris faptul că tuturor etichetelor punctelor ce au intervenit în calcul (predecesorii punctului curent) le va corespunde o aceeaşi etichetă, şi anume eticheta de valoare minimă a acestora. Dacă punctul curent are predecesorii P_1, P_2, P_3, P_4 (cel mult patru predecesori, în cazul folosirii conexităţii V_8), atunci fie m valoarea minimă a etichetelor acestora, $m = min(P_i)$. Varianta pseudocod a prelucrării este prezentată în tabelul 5.2.

pentru toţi predecesorii P_i
  cât timp $T(Pi) \neq m$ **execută**
    $temp = T(P_i)$
    $T(P_i) = m$
    $P_i = temp$

Tabela 5.2: *Pseudocodul corespunzător etichetării cu tabel de corespondenţă între etichete: actualizarea tabelului de corespondeţă între etichete.*

După primul baleiaj al imaginii, tabelul de corespondenţă este actualizat astfel încât fiecărui indice să îi corespundă eticheta finală a obiectului; etichetele atribuite obiectelor nu vor fi neapărat în ordine. Pseudocodul corespunzător acestei prelucrări este dat în tabelul 5.3. Finalul algoritmului (deci după actualizarea tabelului de corespondenţe) construieşte imaginea de etichete finală prin înlocuirea în imaginea intermediară de etichete a fiecărei valori j cu $T(j)$.

pentru j **de la** 1 **la** $j_{\max}$
  $k = j$
  cât timp $T(k) \neq k$ **execută**
    $k = T(k)$
  $T(j) = k$

Tabela 5.3: *Pseudocodul corespunzător actualizării tabelei de corespondenţe între etichete.*

5.2 Segmentarea în spaţiul caracteristicilor

Algoritmii de segmentare orientată pe regiuni în spaţiul caracteristicilor se bazează pe reprezentarea pixelilor din imagine, din domeniul spaţial iniţial, într-un spaţiu alternativ,

definit de valorile caracteristice pixelilor respectivi. În acest spaţiu al caracteristicilor se presupune că separarea dintre elementele ce aparţin unor obiecte de tip diferit este uşor de realizat, întrucât caracteristicile folosite pentru reprezentare sunt discriminante pentru tipurile de obiecte căutate.

5.2.1 Segmentarea pe histogramă

Cel mai simplu şi evident parametru de caracterizare este chiar nivelul de gri al pixelilor, ce corespunde în scenă unei proprietăţi fizice ce este preluată de senzorul de imagine. În acest caz, histograma imaginii reflectă distribuţia în scenă a proprietăţii fizice înregistrate. Dacă nivelul de gri (respectiv proprietatea fizică pe care acesta o reprezintă) caracterizează în mod suficient obiectele din scenă, histograma imaginii va prezenta o structură de moduri dominante – intervale disjuncte de nivele de gri ce apar cu probabilitate mai mare. Fiecare asemenea mod (maxim al histogramei) va reprezenta o anumită categorie de obiecte şi vom numi *clasă* intervalul de nivele de gri alocat unui anume tip de obiect (vezi figura 5.5). După cum am arătat şi în secţiunea 2.2, histograma unei imagini cu M nivele de gri este dată de:

$$h(i) = \frac{N_i}{L \times C} = \frac{1}{L \times C} \sum_{l=0}^{L-1} \sum_{c=0}^{C-1} \delta\left(f(l,c) - i\right) \qquad i = 0, 1, \ldots, M-1, \tag{5.4}$$

unde N_i este numărul de pixeli din imagine ce au nivelul de gri i, L şi C reprezintă numărul de linii şi de coloane ale imaginii, iar δ este funţia indicator.

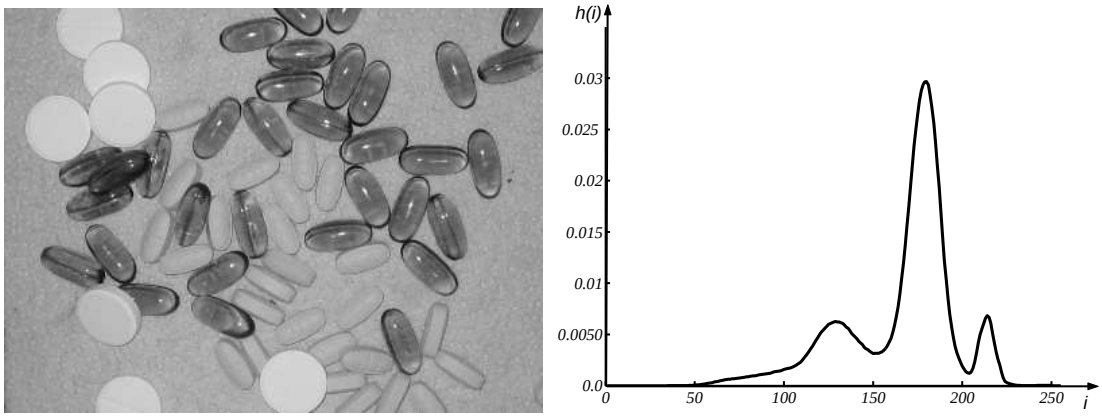


Figura 5.5: *Exemplu de imagine cu nivele de gri având o histogramă trimodală, cu moduri bine separate: primul mod (corespunzând tonurilor de gri celor mai întunecate) corespunde obiectelor închise, modul central, maxim, corespunde fundalului şi obiectelor gri, iar ultimul mod corespunde regiunilor celor mai luminoase din imagine – obiectele rotunde. Histograma conduce la segmentarea imaginii în 3 clase.*

Segmentarea pe histogramă (numită şi prăguire sau *thresholding*) urmăreşte determinarea unor nivele de gri ce separă modurile histogramei, numite praguri de segmentare. Tuturor punctelor din imagine al căror nivel de gri corespunde aceluiaşi mod (deci care au un nivel de gri situat în intervalul dintre două praguri succesive), li se asociază o etichetă comună, a cărei semnificaţie este de apartenenţă a punctului la obiectul respectiv. Segmentarea

imaginii originale f după setul de praguri $\{T_k\}$ produce imaginea etichetată g, descrisă de:

$$g(l,c) = E_k \qquad \text{dacă } T_k \leq f(l,c) < T_{k+1} \tag{5.5}$$

unde $T_0 = 0$, $T_K = M$ şi $k = 0, 1, ..., K-1$. Pragurile T_k pot fi alese manual, prin inspecţia histogramei, în minimele locale ale acesteia.

Cazul cel mai simplu de segmentare pe histogramă este acela în care histograma imaginii este bimodală, corespunzând unei imagini în care regăsim obiecte de interes şi fundal (precum imaginea prezentată în figura 5.6). În acest caz, segmentarea revine la împărţirea pixelilor imaginii în obiecte/fundal, operaţie ce necesită determinarea unui singur nivel de gri de separaţie T. Acest prag de segmentare poate fi ales pe minimul histogramei ce separă modurile acesteia (dacă separaţia este evidentă). Astfel, pornind de la imaginea iniţială f, imaginea etichetată g va fi dată de:

$$g(l,c) = \begin{cases} E_0 & \text{dacă } 0 \leq f(l,c) < T \\ E_1 & \text{dacă } T \leq f(l,c) < M \end{cases} \tag{5.6}$$

Imaginea etichetată g – rezultatul transformării – va fi descrisă de cele două etichete: eticheta E_0 pentru punctele al căror nivel de gri este mai mic decât pragul T şi eticheta E_1 pentru punctele al căror nivel de gri este mai mare decât pragul T. Etichetele E_0 şi E_1 pot fi valori numerice (0 şi 1, sau 0 şi 255) sau pot fi şiruri de simboluri. Acest tip de segmentare se numeşte binarizare, întrucât imaginea rezultat este caracterizată de numai două valori.

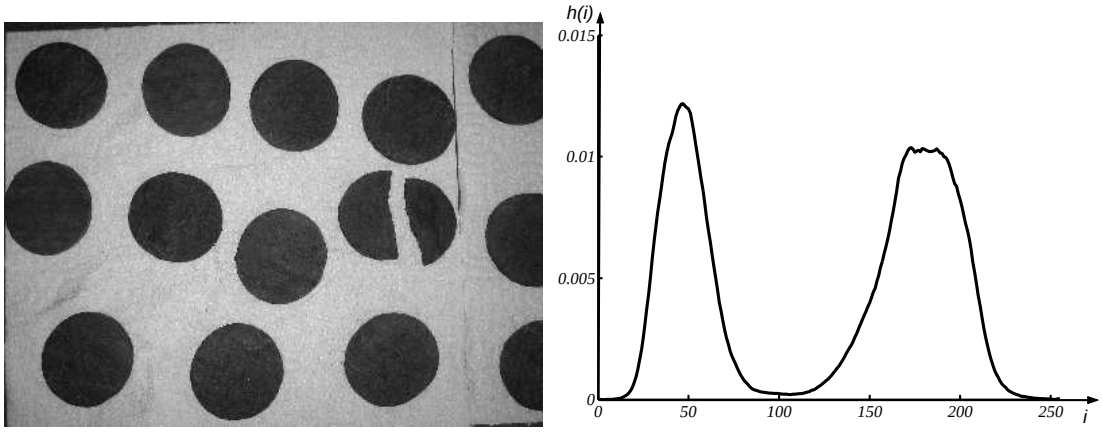


Figura 5.6: *Exemplu de imagine cu nivele de gri având o histogramă bimodală, cu moduri bine separate: primul mod (corespunzând tonurilor de gri celor mai întunecate) corespunde obiectelor închise iar al doilea mod corespunde fundalului; nici unul dinte moduri nu este normal (gaussian).*

Una din cerinţele de bază în majoritatea aplicaţiilor de analiză a imaginilor este ca aceste aplicaţii să necesite o intervenţie umană minimă, deci să lucreze în mod automat. Se pune, deci, problema alegerii automate a pragului (sau pragurilor) de segmentare T_k, pe baza analizei automate a histogramei imaginii şi a eventualelor cunoştinţe a priori asupra conţinutului imaginii.

Metoda Bhattacharya

Metoda Bhattacharya este o metodă automată de segmentare pe histogramă, ce nu necesită precizarea numărului de clase de obiecte din imagine (şi implicit a numărului de praguri de segmentare căutate), ce se bazează pe descompunerea histogramei în moduri individuale normale (gaussiene) [12], [66]. Se presupune deci că histograma imaginii poate fi exprimată ca o mixtură (sumă ponderată) de funcţii de densitate de probabilitate de tip normal, fiecare dintre acestea corespunzând unui mod al histogramei. Se consideră deci că histograma h a imaginii este compusă prin superpoziţia aditivă a K moduri gaussiene $\mathcal{N}(\mu_k, \sigma_k)$, adică:

$$h(i) = \sum_{k=1}^{K} w_k \mathcal{N}(\mu_k, \sigma_k)(i),\ i = 0, ..., M-1,\ \text{cu}\ \sum_{k=1}^{K} w_k = 1. \tag{5.7}$$

Modelarea modurilor histogramei imaginilor prin distribuţii normale este o presupunere ce se întâlneşte în multe tehnici de prelucrare şi analiză şi pare a fi justificată de considerarea extrem de simplificată a imaginii ca provenind dintr-o imagine ideală, în care fiecare tip de obiect este reprezentat de un unic nivel de gri, peste care s-a suprapus un zgomot alb, aditiv, gaussian. În acest fel, mediile modurilor din histogramă corespund nivelelor de gri ce caracterizează obiectele scenei, iar varianţele acestor moduri sunt determinate de zgomotul suprapus imaginii (care nu este obligatoriu să afecteze în acelaşi mod toate nivelele de gri).

Fundamentul metodei Bhattacharya [5] este determinarea parametrilor caracteristici (medie, varianţă) ai unei distribuţii normale. Pentru distribuţia normală $\mathcal{N}(\mu_k, \sigma_k)$ derivata logaritmului este:

$$\frac{\mathrm{d}}{\mathrm{d}x} \ln \mathcal{N}(\mu_k, \sigma_k)(x) = \frac{\mathrm{d}}{\mathrm{d}x} \ln \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x-\mu_k)^2}{2\sigma_k^2}\right) = -\frac{x}{\sigma_k^2} + \frac{\mu_k}{\sigma_k^2} = m_k x + n_k. \tag{5.8}$$

Prin examinarea expresiei (5.8) se observă că derivata logaritmului distribuţiei normale este o dreaptă de pantă negativă, din ai cărei parametri se pot deduce media şi varianţa distribuţiei prin (5.9):

$$\sigma_k = \sqrt{\frac{1}{|m_k|}}\ \text{şi}\ \mu_k = \frac{n_k}{|m_k|}. \tag{5.9}$$

Dacă se presupune că distribuţiile normale individuale ce compun histograma sunt suficient de bine separate pentru ca să existe, pentru fiecare componentă, o regiune suficient de mare în care influenţa tuturor celorlalte componente să fie neglijabilă, acelaşi principiu de identificare poate fi aplicat pentru întreaga histogramă [5]. Pentru aplicarea metodei Bhattacharya la segmentarea pe histogramă a imaginilor, se va studia comportamentul derivatei logaritmului histogramei, adică a funcţiei discriminant $z(i)$:

$$z(i) = \ln \frac{h(i)}{h(i-1)},\ i = 1, ..., M-1. \tag{5.10}$$

Pentru funcţia astfel construită, se determină intervalele pe care acesta este descrescătoare (vezi Figura 5.7); limitele superioare ale acestor intervale sunt pragurile T_k de segmentare

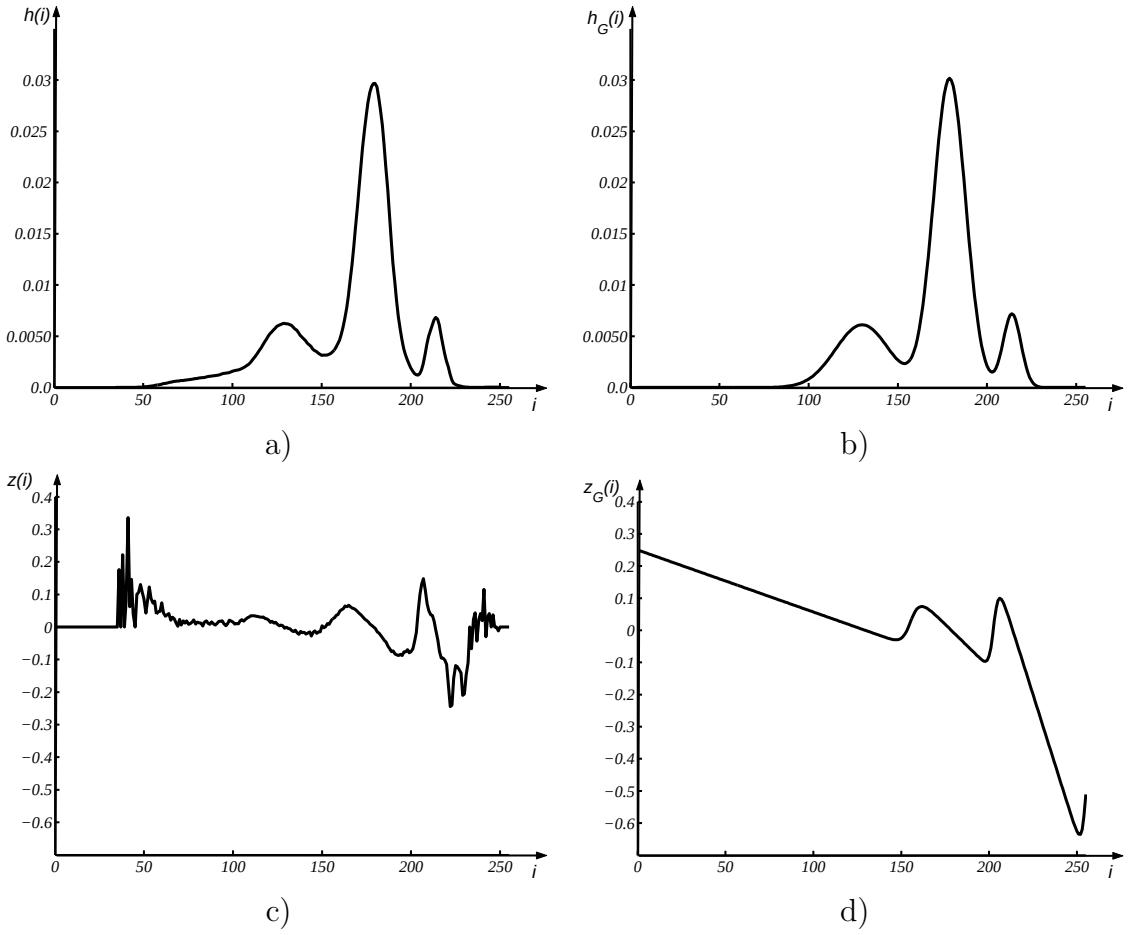


Figura 5.7: *Aplicarea metodei Bhattacharyya pentru o histogramă trimodală: pragurile de segmentare T_k sunt limitele superioare ale intervalelor pe care funcţia discriminant (derivata logaritmului histogramei) este descrescătoare. a) Histogramă trimodală (a imaginii din figura 5.5) şi c) funcţia discriminant $z(i)$ asociată. b) Aproximarea histogramei din a) printr-o mixtură de moduri normale ($h = 0.23\mathcal{N}(129, 15) + 0.68\mathcal{N}(178, 9) + 0.09\mathcal{N}(213, 5)$) şi d) funcţia discriminant asociată. Se observă că identificarea pragurilor de segmentare (155, 202) prin funcţia indicator este simplă în cazul histogramei ideale b) şi mai dificilă în cazul histogramei reale a).*

pe histogramă. Pe fiecare dintre aceste intervale se poate face o aproximare liniară a punctelor şi pe baza parametrilor deduşi pentru dreapta de aproximare se pot calcula, conform (5.9), parametrii statistici locali. Principalele inconveniente ale metodei derivă din faptul că presupunerea alcătuirii histogramei imaginii numai din moduri gaussiene nu este întotdeauna adevărată. Ca rezultat, metoda Bhattacharrya va identifica un număr mai mare de praguri decât este necesar, producând fenomenul de suprasegmentare. Acest comportament poate fi însă reconsiderat din punctul de vedere al cuantizării nivelelor de gri. Putem considera cuantizarea (aproximarea) valorilor cuprinse în fiecare interval corespunzător unui mod gaussian identificat prin media acestuia. În acest caz, eroarea de cuantizare este cu atât mai mică cu cât sunt mai multe moduri gaussiene în mixtura ce aproximează histograma imaginii. Controlul acestei erori de cuantizare (şi implicit al fenomenului de suprasegmentare)poate fi realizat prin impunerea unei lungimi minime a intervalelor de descreştere a funcţiei discriminant z (5.10) [66]. Un exemplu de cuantizare a nivelelor de gri realizată după această metodă este prezentat în figura 5.9.

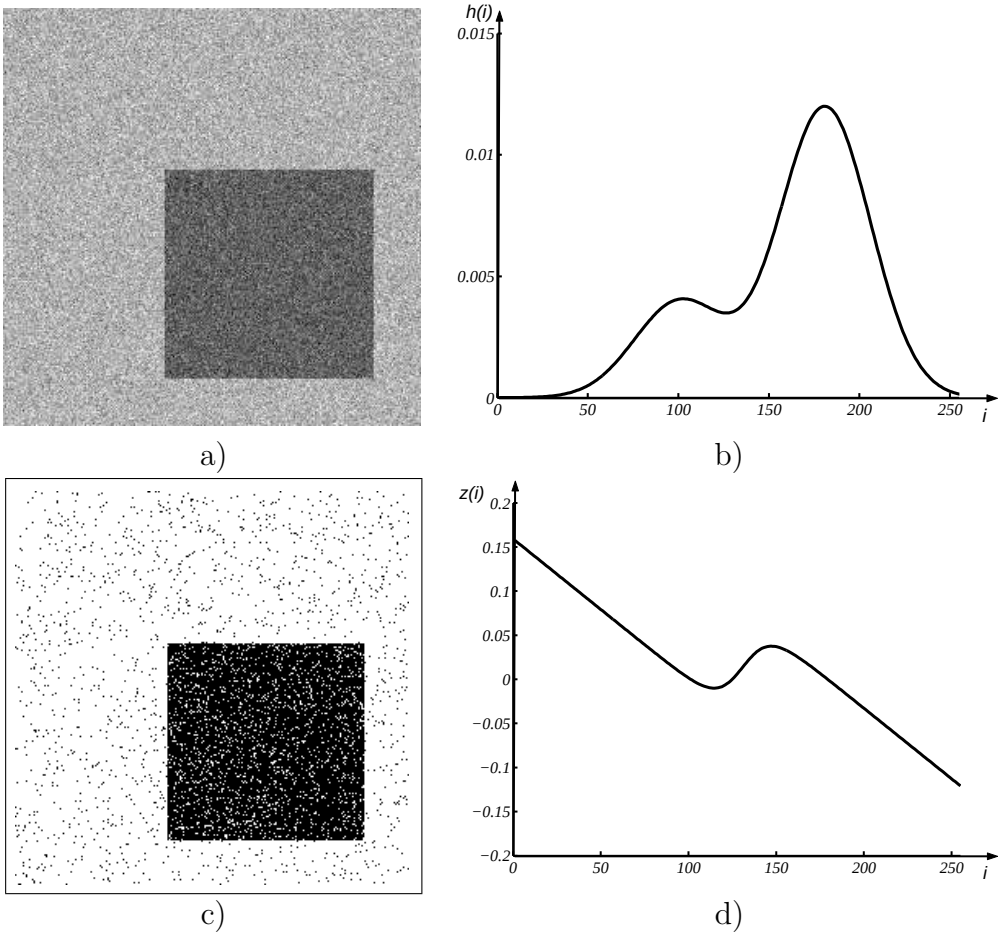


Figura 5.8: *Aplicarea metodei Bhattacharyya pentru segmentarea unei imagini cu histogramă bimodală: a) imaginea originală; b) histograma imaginii de segmentat (histograma este mixtura* $h = 0.25\mathcal{N}(100, 25) + 0.75\mathcal{N}(180, 25)$*); c) imaginea binarizată folosind pragul* $T = 132$ *obţinut prin aplicarea metodei Bhattacharya; d) funcţia discriminant* z*.*

Metoda Otsu

Metoda Otsu de determinare automată a pragurilor de segmentare este legată de utilizarea principiului de cuantizare optimală a nivelelor de gri, cuantizare ce va asigura (ca şi în cazul metodei Bhattacharya, prezentate în paragraful anterior) determinarea unor intervale de nivele de gri în care modurile histogramei imaginii să fie înguste şi care, în consecinţă, să inducă o variabilitate mică a valorilor iniţiale faţă de media fiecărui mod determinat (medie ce este folosită ca valoare de cuantizare). Pragurile de segmentare determinate de metoda Otsu sunt chiar capetele intervalelor de cuantizare optimală a nivelelor de gri din imagine cu un număr de cuante egal cu numărul de clase de segmentare.

După cum se ştie (se poate revedea de exemplu capitolul 11 din [11]), cuantizarea unei mulţimi de valori implică înlocuirea valorilor respective cu cea mai apropiată valoare dintr-o mulţime finită de valori (mulţimea valorilor cuantizate). Operaţia de cuantizare este o aproximare a valorilor iniţiale prin valorile cuantizate, mai exact, aproximarea tuturor valorilor cuprinse într-un interval $(x_i, x_{i+1}]$ cu o valoare cuantizată y_i. În cuantizarea

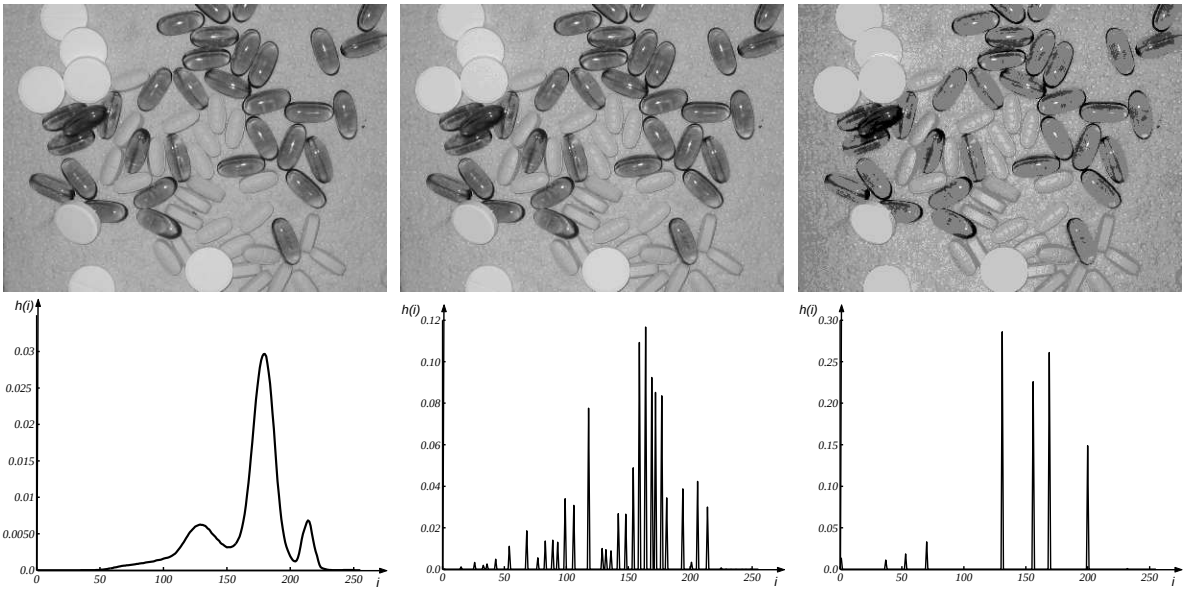


Figura 5.9: *Exemplu de cuantizare a nivelelor de gri prin metoda Bhattacharya: pe rândul de sus sunt prezentate imaginea originală cu 212 nivele de gri diferite (stânga) şi variantele cuantizate cu 39 de nivele de gri diferite (mijloc,* $RSZ = 41,18dB$*) şi respectiv 10 nivele de gri diferite (dreapta,* $RSZ = 23,11dB$*); pe rândul de jos sunt prezentate histogramele corespunzătoare fiecărei imagini. În cazul re-cuantizării uniforme a nivelelor de gri la 39, respectiv 10, raportul semnal zgomot al imaginiilor rezultate ar fi* $RSZ = 33,26dB$*, respectiv* $RSZ = 21,25dB$*; re-cuantizarea bazată pe metoda Bhattacharya este deci mult mai eficientă.*

optimală Lloyd-Max (prezentată pe larg în [11], [33]) valorile cuantizate şi intervalele de cuantizare sunt determinate astfel încât media pătratică a erorii induse de aproximarea valorilor iniţiale cu cele cuantizate să fie minimă pentru un număr de nivele de cuantizare dat.

Se poate demonstra că valorile cuantizate care minimizează eroarea pătratică medie de aproximare sunt mediile statistice ale valorilor din intervalul de cuantizare respectiv. Altfel spus, cuantizarea optimală înseamnă alegerea intervalelor de cuantizare astfel încât valorile din fiecare interval să fie cât mai apropiate de media lor, adică varianţa valorilor din fiecare interval de cuantizare să fie minimă. Eroarea de cuantizare va fi atunci varianţa medie corespunzătoare tuturor intervalelor de cuantizare alese. Într-adevăr, putem scrie eroarea pătratică medie de cuantizare a valorilor realizărilor particulare ale unei variabile

aleatoare ξ, distribuită după funcţia de densitate de probabilitate w_ξ ca:

$$\begin{aligned}\varepsilon &= \sum_{i=1}^{K} \int_{x_i}^{x_{i+1}} \left(x - \overline{\xi}|\{x_i \le \xi \le x_{i+1}\}\right)^2 w_\xi(x)\mathrm{d}x = \\ &= \sum_{i=1}^{K} \underbrace{\int_{x_i}^{x_{i+1}} w_\xi(z)\mathrm{d}z}_{P(x_i \le \xi \le x_{i+1})} \underbrace{\int_{x_i}^{x_{i+1}} \left(x - \overline{\xi}|\{x_i \le \xi \le x_{i+1}\}\right)^2 \frac{w_\xi(x)}{\underbrace{\int_{x_i}^{x_{i+1}} w_\xi(z)\mathrm{d}z}_{w_{\xi|\{x_i \le \xi \le x_{i+1}\}}}}\mathrm{d}x}_{\sigma^2_{\xi|\{x_i \le \xi \le x_{i+1}\}}}. \\ &= \sum_{i=1}^{K} P(x_i \le \xi \le x_{i+1})\sigma^2_{\xi|\{x_i \le \xi \le x_{i+1}\}} = \sum_{i=1}^{K} P_i\sigma_i^2.\end{aligned} \tag{5.11}$$

Pentru simplitate, am folosit notaţiile:

$$P_i \overset{\text{not}}{=} P(x_i \le \xi \le x_{i+1}) \tag{5.12}$$

$$\sigma_i \overset{\text{not}}{=} \sigma_{\xi|\{x_i \le \xi \le x_{i+1}\}} \tag{5.13}$$

În cazul binarizării, problema (care fusese iniţial formulată doar ca alegere a pragului de segmentare T care separă modurile histogramei ce corespund celor două tipuri de obiecte din imagine) poate fi reformulată în sensul cuantizării: dorim cuantizarea optimală a valorilor pixelilor imaginii cu $K = 2$ nivele, ceea ce revine la determinarea pragului T astfel încât prin împărţirea gamei de nivele de gri disponibile $[0, M-1]$ în două subintervale, $[0, T]$ şi $[T, M-1]$, şi prin aproximarea fiecărui pixel dintr-un subinterval cu media acestuia, eroarea pătratică medie să fie minimă. Astfel, conform (5.11), pragul T cu care facem binarizarea trebuie să minimizeze expresia:

$$\varepsilon = P_0\sigma_0^2 + P_1\sigma_1^2, \tag{5.14}$$

unde P_0 şi P_1 sunt probabilităţile ca nivelul de gri al unui pixel să aparţină intervalelor $[0, T-1]$, respectiv $[T, M-1]$:

$$P_0 = \sum_{i=0}^{T-1} h(i), \tag{5.15a}$$

$$P_1 = \sum_{i=T}^{M-1} h(i) = 1 - P_0, \tag{5.15b}$$

iar σ_0^2 şi σ_1^2 sunt varianţele nivelelor de gri corespunzătoare aceloraşi intervale:

$$\sigma_0^2 = \frac{\sum_{i=0}^{T-1} i^2 h(i)}{\sum_{i=0}^{T-1} h(i)} - \left(\frac{\sum_{i=0}^{T-1} ih(i)}{\sum_{i=0}^{T-1} h(i)}\right)^2, \tag{5.16a}$$

$$\sigma_1^2 = \frac{\sum_{i=T}^{M-1} i^2 h(i)}{\sum_{i=T}^{M-1} h(i)} - \left(\frac{\sum_{i=T}^{M-1} ih(i)}{\sum_{i=T}^{M-1} h(i)}\right)^2. \tag{5.16b}$$

După cum s-a arătat [11], pragul căutat T este media aritmetică a mediilor statistice ale valorilor de cuantizat din cele două intervale de cuantizare alese (notate cu μ_0 şi μ_1); ţinând seama că nivele de gri din imagine sunt (deja) valori discrete, expresia pragului T se poate scrie ca:

$$T = \frac{1}{2}\left(\underbrace{\frac{\sum_{i=0}^{T-1} ih(i)}{\sum_{i=0}^{T-1} h(i)}}_{\mu_0} + \underbrace{\frac{\sum_{i=T}^{M-1} ih(i)}{\sum_{i=T}^{M-1} h(i)}}_{\mu_1} \right). \tag{5.17}$$

Această ecuaţie nu se poate rezolva analitic. Putem găsi totuşi valoarea T căutată, care minimizează pe (5.14) calculând valorile unei forme modificate ale funcţiei (5.14) pentru toate valorile posibile ale lui $T \in \{0, 1, \ldots, M-1\}$. Pentru aceasta, (5.14) se poate rescrie ca:

$$\varepsilon = \sum_{i=0}^{M-1} i^2 h(i) - \left(P_0\mu_0^2 + P_1\mu_1^2 \right). \tag{5.18}$$

Minimizarea lui (5.14) revine la maximizarea lui $P_0\mu_0^2 + P_1\mu_1^2$. O simplificare a calculului se poate obţine prin considerarea relaţiilor iterative prin care mediile şi probabilităţile de apariţie pe intervale, calculate pentru pragul $T+1$ depind de aceleaşi mărimi calculate pentru pragul imediat anterior, T. De exemplu avem:

$$P_0(T+1) = P_0(T) + h(T+1) \tag{5.19}$$

$$\mu_0(T+1) = \frac{P_0(T)\mu_0(T) + (T+1)h(T+1)}{P_0(T+1)}. \tag{5.20}$$

Relaţii analoage există pentru mărimile P_1 şi μ_1.

O formulare echivalentă a criteriului de determinare a pragurilor de segmentare se regăseşte şi în metoda Fisher [12], în care varianţa medie corespunzătoare intervalelor de cuantizare este adusă sub forma:

$$\varepsilon = \sum_{i=0}^{M-1} i^2 h(i) - P_0 P_1 \left(\mu_1 - \mu_0 \right)^2. \tag{5.21}$$

Segmentarea cu prag optim

Binarizarea unei imagini cu nivele de gri poate fi interpretată şi ca o problemă de decizie – trebuie hotărâtă clasa (tipul de obiect) căreia îi aparţine fiecare punct din imagine. Decizia se reduce, desigur, la calculul pragului de segmentare T, cu care se compară nivelele de gri ale pixelilor din imagine, astfel încât clasificarea pixelilor în clase să fie cât mai corectă din punctul de vedere al unui criteriu de eroare. Pragul astfel determinat va fi optim în sensul criteriului de eroare folosit, segmentarea numindu-se segmentare cu prag optim.

În cazul binarizării trebuie determinat deci un unic prag T ce separă modurile din histogramă ce corespund celor două obiecte din imagine: obiecte O_0, caracterizate de nivele de gri mai mici decât pragul T, şi obiecte O_1, ale căror nivele de gri sunt mai mari decât

pragul T. Binarizarea se poate formula într-un cadru specific proceselor de decizie, considerând că pentru fiecare pixel al imaginii se ia decizia D_0 (respectiv se decide că pixelul aparţine unui obiect O_0) dacă nivelul său de gri este mai mic decât pragul T, sau decizia D_1 (pixelul aparţine unui obiect O_1) dacă nivelul de gri al pixelului este mai mare decât pragul T. După cum se poate remarca, observaţia pe baza căreia luăm decizia este un scalar, şi anume nivelul de gri al pixelului respectiv.

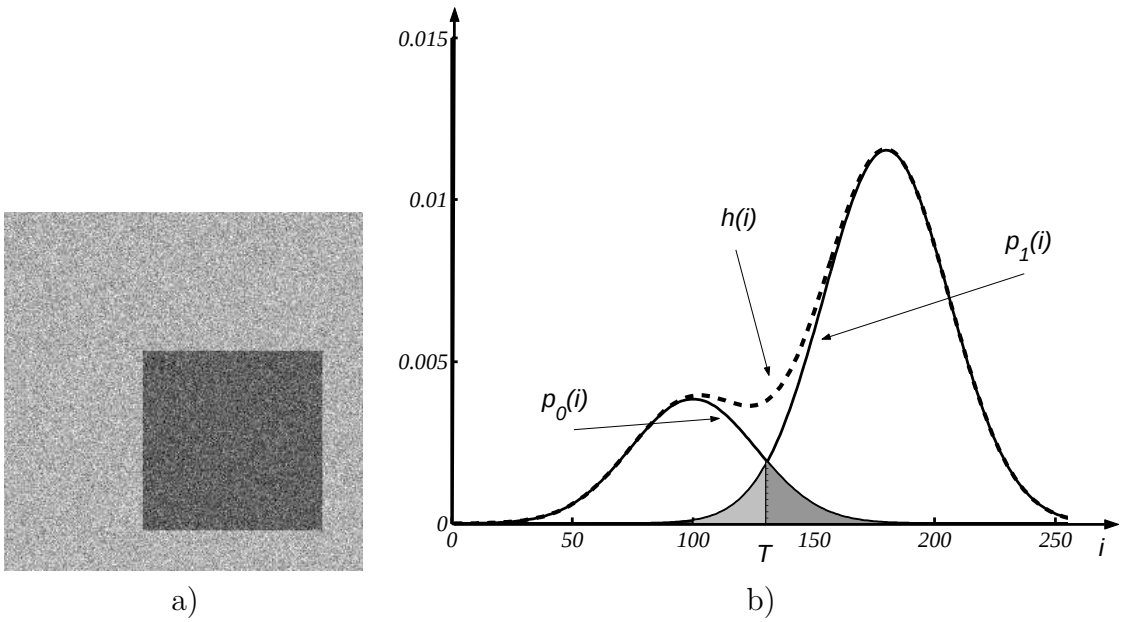
Criteriul ce se urmăreşte optimizat este minimizarea probabilităţii de clasificare eronată a punctelor din imagine. Presupunând cunoscute funcţiile de densitate de probabilitate a nivelelor de gri ce descriu fiecare dintre cele două tipuri de componente din imagine, $p_0(i)$ şi $p_1(i)$ şi probabilităţile lor de apariţie în imagine, P_0 şi P_1, putem exprima probabilitatea de clasificare eronată ca:

$$\varepsilon(T) = P_0 P(D_1|O_0) + P_1 P(D_0|O_1) = P_0 \int_T^{+\infty} p_0(x)\mathrm{d}x + P_1 \int_{-\infty}^{T} p_1(x)\mathrm{d}x. \tag{5.22}$$

În mod evident se presupune că cele două tipuri de obiecte ocupă complet imaginea ($P_0 + P_1 = 1$). Histograma imaginii (adică distribuţia nivelelor de gri la nivelul întregii imagini) este evident mixtura distribuţiilor individuale ale celor două tipuri de obiecte şi se poate scrie ca:

$$h(i) = P_0 p_0(i) + P_1 p_1(i), \qquad i = 0, 1, \ldots, M-1. \tag{5.23}$$

Figura 5.10 prezintă o ilustrare grafică a erorii.



a) b)

Figura 5.10: *a) Imagine bimodală şi b) reprezentarea erorii de clasificare corespunzătoare separării celor două moduri (gaussiene) prin pragul T prin aria de subgrafic haşurată. Histograma imaginii corespunde ecuaţiei* (5.23) *şi este figurată pe grafic cu linie punctată.*

Pragul optim va minimiza eroarea de segmentare a pixelilor. Minimizarea erorii (5.22) conduce la rezolvarea ecuaţiei în necunoscuta T:

$$\frac{\partial \varepsilon(T)}{\partial T} = 0, \tag{5.24}$$

ceea ce conduce la relaţia:

$$-P_0 p_0(T) + P_1 p_1(T) = 0, \tag{5.25}$$

ce poate fi rescrisă ca:

$$\frac{p_1(T)}{p_0(T)} = \frac{P_0}{P_1}. \tag{5.26}$$

Forma (5.26) se poate compara cu forma clasică finală a criteriului de decizie Bayes (se poate urmări de exemplu prezentarea din [11]); constatăm astfel că ne aflăm într-un cadru de alegere simetrică a costurilor de decizie (ambele erori de decizie au acelaşi cost, ambele decizii corecte au acelaşi cost), astfel încât pragul testului Bayes este dat de raportul probabilităţilor a priori de apariţie a celor două tipuri de obiecte.

Presupunerea că distribuţia nivelelor de gri a diferitelor tipuri de obiecte este de tip normal (gaussian) este relativ des întâlnită. În aceste condiţii, distribuţiile $p_0(x)$ şi $p_1(x)$ sunt distribuţii normale, $\mathcal{N}(\mu_0, \sigma_0)$ şi $\mathcal{N}(\mu_1, \sigma_1)$, iar ecuaţia (5.26) devine:

$$\frac{\frac{1}{\sigma_1\sqrt{2\pi}} \exp\left(-\frac{(T-\mu_1)^2}{2\sigma_1^2}\right)}{\frac{1}{\sigma_0\sqrt{2\pi}} \exp\left(-\frac{(T-\mu_0)^2}{2\sigma_0^2}\right)} = \frac{P_0}{P_1} \tag{5.27}$$

Prin logaritmare, se obţine o ecuaţie de gradul doi prin a cărei rezolvare se determină pragul necunoscut T:

$$T^2\left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}\right) - 2T\left(\frac{\mu_0}{\sigma_0^2} - \frac{\mu_1}{\sigma_1^2}\right) + \left(\frac{\mu_0^2}{\sigma_0^2} - \frac{\mu_1^2}{\sigma_1^2}\right) - 2\ln\frac{P_0}{P_1}\frac{\sigma_1}{\sigma_0} = 0. \tag{5.28}$$

Pentru cazul particular $\sigma_0 = \sigma_1 = \sigma$, ecuaţia (5.28) devine o ecuaţie de gradul unu, a cărei soluţie este:

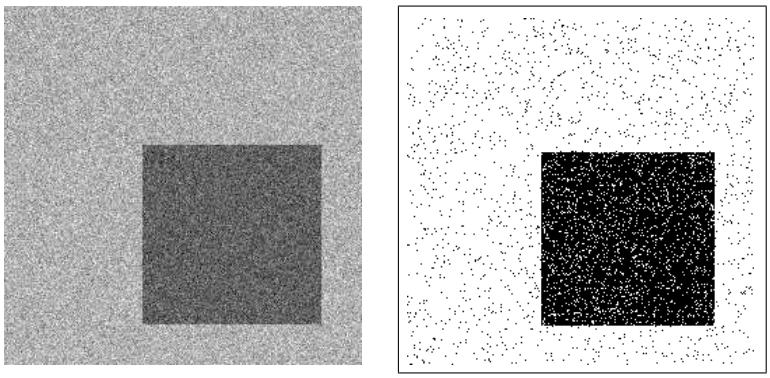
$$T = \frac{\mu_0 + \mu_1}{2} - \frac{\sigma^2}{\mu_0 - \mu_1}\ln\frac{P_0}{P_1} \tag{5.29}$$

În cazul imaginii reprezentate în figura 5.10 a), parametrii statistici sunt $\mu_0 = 100$, $\mu_1 = 180$, $\sigma_0 = \sigma_1 = \sigma = 25$, $P_0 = 0.25$; pragul optim de segmentare, calculat conform (5.29) este $T = 131$. Rezultatul segmentării cu prag optim este reprezentat în figura 5.11.

Metoda de segmentare cu prag optim se poate extinde şi pentru imagini ce conţin mai mult de două tipuri de obiecte; în acest caz este însă necesară o presupunere suplimentară de localizare a modurilor, astfel încât să se poată considera că influenţa fiecărui mod este limitată la intervale nesuprapuse de nivele de gri şi deci eroarea de clasificare a pixelilor imaginii se va referi doar la perechi de moduri vecine.

Segmentarea pe histograma ponderată

Metodele de segmentare pe histogramă pot fi rafinate prin luarea în considerare la determinarea pragurilor de segmentare nu numai a proprietăţilor globale (ale întregii imagini), aşa cum este histograma (5.4), ci şi a unor mărimi caracteristice fiecărui pixel, determinate de vecinătatea acestuia. Altfel spus, pragurile de segmentare, care în mod clasic se aleg



a) b)

Figura 5.11: *a) Imagine bimodală cu nivele de gri şi b) rezultatul binarizării acesteia prin segmentare cu prag optim ($T = 131$). Eroarea de segmentare este, în cazul segmentării cu prag optim prezentate, de* 5.5%*; în cazul folosirii unui prag $T = 140$ (mijlocul intervalului dintre mediile modurilor histogramei), eroarea de segmentare este de* 6.29%*; în cazul folosirii pragului $T = 132$ determinat prin metoda Bhattacharya, eroarea de segmentare este de* 5.57%*.*

pe minimele histogramei, se vor alege în punctele de extrem ale unei histograme modificate, ce încorporează informaţia rezultată din structura de vecinătate a pixelilor. Această tehnică este numită segmentare pe histograma ponderată în [68] sau segmentare cu prag selectiv în [33]. Construirea histogramei ponderate are ca scop accentuarea minimelor din histograma clasică, pentru o alegere mai uşoară a pragurilor de segmentare (valorile de separaţie inter-mod). Histograma ponderată este construită prin definirea unei funcţii de ponderare $w()$, care transformă o anumită proprietate locală $p(l, c)$, conform relaţiei (5.30):

$$h_w(i) = \frac{1}{L \times C} \sum_{l=0}^{L-1} \sum_{c=0}^{C-1} w\left(p(l,c)\right) \delta(i - f(l,c)),\ i = 0, 1, \ldots, M-1. \tag{5.30}$$

În această histogramă ponderată, spre deosebire de histograma clasică (5.4), contribuţia pixelilor nu mai este unitară, ci dependentă de proprietăţile vecinătăţii acestora. Proprietatea locală cea mai des utilizată este aceea de neuniformitate (de variaţie a nivelelor de gri în vecinătatea fiecărui pixel), măsurată prin laplacianul local $\Delta(l, c)$. Pixelii care se află în zonele de tranziţie (frontierele obiectelor din imagine) au o vecinătate neuniformă, şi deci un laplacian semnificativ diferit de zero, iar pixelii care se afla în interiorul unor regiuni uniforme (interiorul obiectelor) au o vecinătate mai uniformă şi deci un laplacian apropiat de valoarea nulă. Pentru a accentua pe histogramă zonele de separaţie inter-mod este necesar ca pixelii ce se află în interiorul unor regiuni uniforme (obiecte) să aibă o contribuţie mai importantă decât contribuţia pixelilor aflaţi în zonele de frontieră. În aceste condiţii, funcţia de ponderare trebuie să fie invers proporţională cu laplacianul local; forma generală a funcţiei de ponderare este dată de relaţia (5.31):

$$w\left(p(l,c)\right) = \frac{1}{1 + |\Delta(l,c)|^k} \tag{5.31}$$

Exponentul k reprezintă un factor suplimentar de reglaj, permiţând obţinerea de diferite grade de reliefare a minimelor histogramei (cu cât k este mai mare, cu atât minimele

sunt mai bine puse în evidenţă). Laplacianul local se poate evalua cu una dintre măştile (nucleele) de convoluţie clasice, precum cele din (6.24).

În [68] se propune un mod de segmentare alternativă, folosind maximele unei histograme ponderate. În acest caz este necesar ca funcţia de ponderare $w()$ să transforme minimele histogramei normale în maxime ale histogramei ponderate. Dacă se foloseşte în continuare laplacianul ca proprietate locală şi o funcţie de ponderare proporţională cu acesta, de exemplu (5.32), histograma ponderată va lua în calcul doar pixelii din imagine a căror vecinătate prezintă variaţii puternice ale nivelelor de gri, în timp ce pixelii aflaţi în interiorul unor regiuni omogene nu vor avea nici o contribuţie. Histograma ponderată astfel construită va prezenta maxime pe nivelele de gri ce corespund zonelor de tranziţie între modurile histogramei normale.

$$w\left(p(l,c)\right) = |\Delta(l,c)| \tag{5.32}$$

O exemplificare a efectelor utilizării acestor ponderări este prezentată în figura 5.12.

Desigur, o altă modalitate de obţinere a unei tehnici locale de segmentare este împărţirea imaginii în zone (ce se pot suprapune sau nu) în interiorul cărora se determină praguri de segmentare prin folosirea unei histograme locale (şi nu a histogramei întregii imagini). Pragurile astfel determinate sunt folosite apoi la etichetarea punctelor din zona respectivă. La limită, dacă pragurile de segmentare astfel determinate sunt folosite pentru etichetarea unui unic pixel, segmentarea capătă un caracter dinamic (adaptiv).

Segmentarea pe histograma cumulativă

După cum am arătat şi în secţiunea 2.2, histograma cumulativă este funcţia de repartiţie a variabilei aleatoare ce reprezintă nivelul de gri al pixelilor imaginii, şi reprezintă deci probabilitatea ca un pixel din imagine să aibă nivelul de gri mai mic decât un prag fixat:

$$H(j) = \sum_{i=1}^{j} h(i),\ j = 0, 1, \ldots, M-1. \tag{5.33}$$

Fiind o funcţie de repartiţie, histograma cumulativă este o funcţie crescătoare şi $H(M-1) = 1$. Exemplul clasic de folosire a tehnicii de segmentare utilizând histograma cumulativă este acela de binarizare a unei imagini ce conţine obiecte de interes şi fundal. În general se consideră că obiectele de interes sunt caracterizate de un nivel de gri mai mic ca al fundalului, şi că obiectele ocupă un procent P, cunoscut, din suprafaţa imaginii (măsurată prin numărul de pixeli) (figura 5.13 prezintă un astfel de exemplu). În aceste condiţii, pragul de segmentare T se va alege astfel încât:

$$H(T) \cong P. \tag{5.34}$$

În cazul în care obiectele de interes au un nivel de gri mai mare decât nivelul de gri al fundalului (şi deci sunt definite de modul situat la capătul superior al histogramei), relaţia de definiţie a pragului (5.34) se va modifica în:

$$H(T) \cong 1 - P \tag{5.35}$$

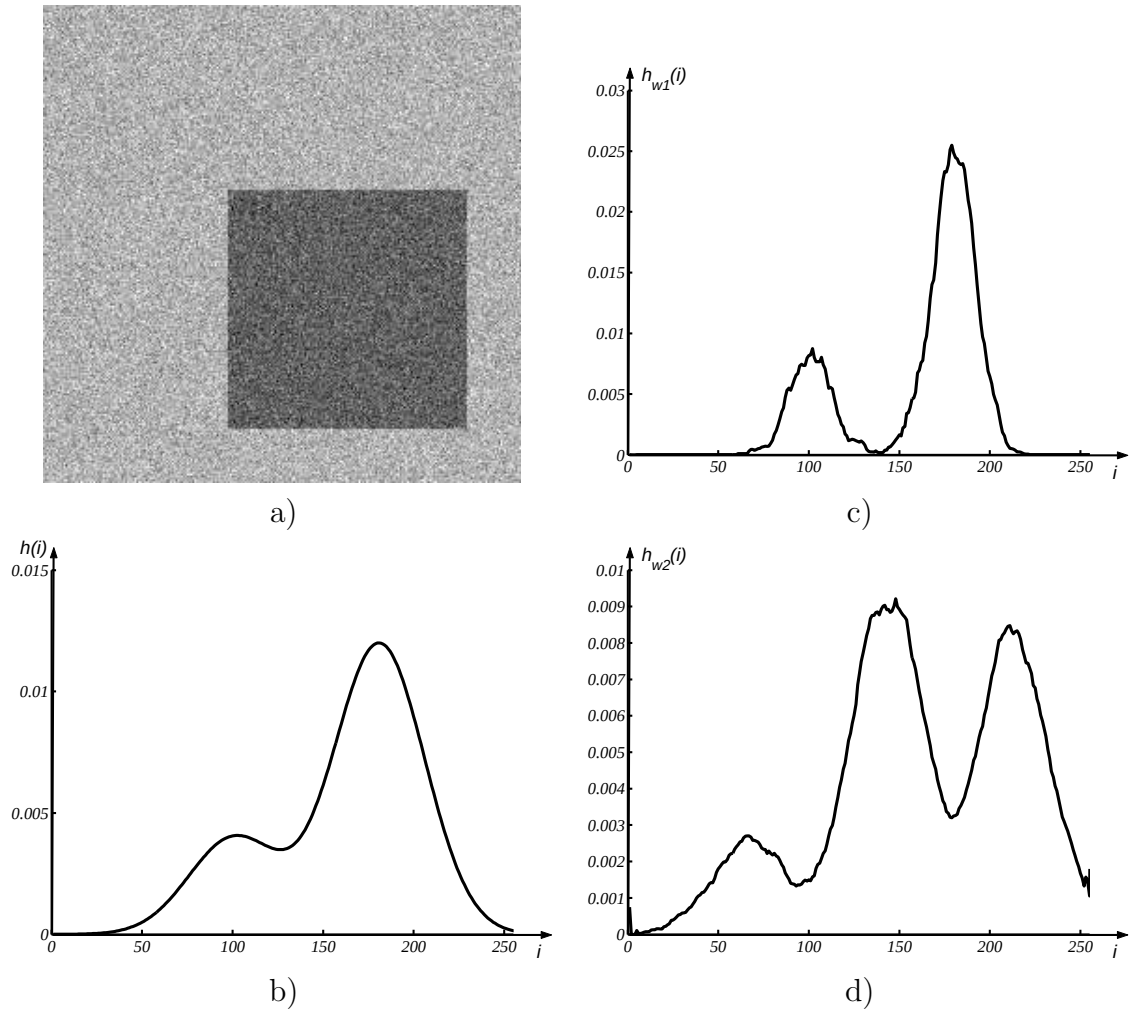


Figura 5.12: *Mărirea separaţiei dintre moduri prin folosirea histogramelor ponderate: a) imagine originală; b) histograma imaginii din a); c) histograma ponderată cu inversul laplacianului (adâncirea separaţiei dintre moduri), conform (5.31); d) histogramă ponderată cu pătratul laplacianului (maxime pe separaţiile dintre moduri), conform (5.32). Histograma originală este* $h = 0.25\mathcal{N}(100, 25) + 0.75\mathcal{N}(180, 25)$. *Pe ambele histograme ponderate pragul de segmentare* $T\widetilde{=}140$ *poate fi determinat foarte uşor.*

Metoda de segmentare pe histograma cumulativă se poate extinde şi în cazul segmentării unor imagini ce conţin mai multe tipuri de obiecte, cu condiţia cunoaşterii probabilităţilor de apariţie a pixelilor corespunzători fiecărui tip de obiecte. Trebuie remarcat că metoda nu necesită cunoaşterea tipului de distribuţie ce caracterizează nivelul de gri al fiecarui tip de obiect.

5.2.2 Segmentarea prin tehnici de clustering

Tehnicile de segmentare pe histogramă prezentate în secţiunea anterioară se bazează implicit pe presupunerea că nivelul de gri (valoarea pixelului) este o caracteristică suficient de discriminativă pentru separarea tipurilor de obiecte din imagine. Deşi adevărată în cele mai multe cazuri, această presupunere devine în mod evident eronată pentru o imagine de tipul celei din figura 5.12 a), în care atât obiectul, cât şi fundalul, conţin pixeli având

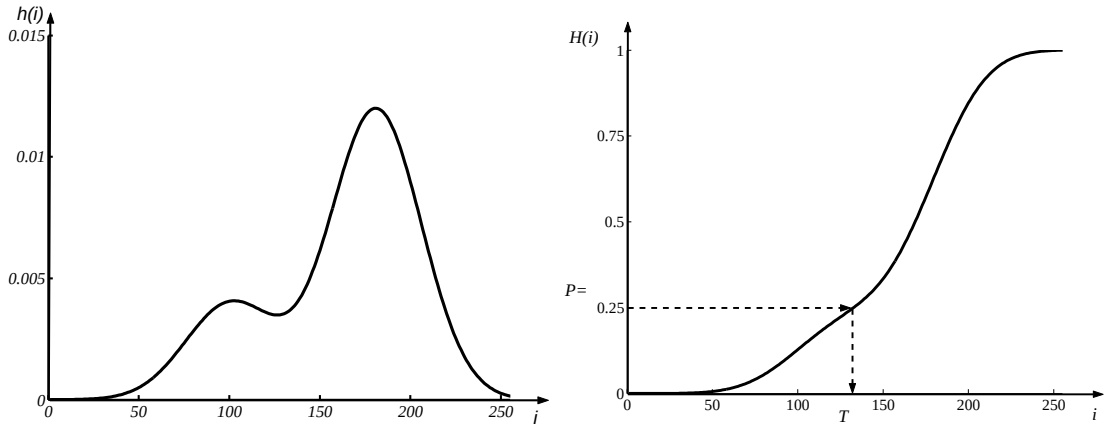


Figura 5.13: *Histograma cumulativă $H(i)$ este funcţia de repartiţie asociată funcţiei de densitate de probabilitate a variabilei aleatoare nivel de gri i (histograma imaginii), $h(i)$. Pentru extragerea obiectelor întunecate din imagine prin segmentare pe histograma cumulativă trebuie impus (cunoscut) procentul P (pentru imaginea corespunzătare exemplului, $P = 0.25$) din suprafaţa imaginii ocupat de obiectele de interes. Pragul de segmentare căutat T se obţine pe baza graficului histogramei cumulative astfel încât să fie îndeplinită relaţia (5.34).*

acelaşi nivel de gri (situaţie ce se poate observa şi din suprapunerea evidentă a celor două moduri ce apar în histograma imaginii, prezentată în figura 5.12 b)). Rezolvarea unor asemenea situaţii se poate face prin luarea în calcul, pentru fiecare pixel, a unor caracteristici suplimentare. În acest caz însă, spaţiul caracteristicilor devine multi-dimensional şi problema de segmentare cu prag (pe histogramă) trebuie reformulată. Spre exemplu, în figura 5.14 se prezintă cazul în care fiecare pixel al imaginii este caracterizat de nivelul de gri şi nivelul de gri mediu din vecinătate, spaţiul caracteristicilor fiind deci bidimensional. Un spaţiu al caracteristicilor cel puţin tridimensional apare în mod natural în cazul considerării imaginilor color, în care fiecare pixel este descris de trei valori (componentele de culoare).

Tehnicile de clustering (sau de auto-organizare a datelor multidimensionale) sunt metode algoritmice prin care se atribuie fiecărui vector de date din mulţimea considerată o etichetă de apartenenţă la una dintre clasele ce rezultă prin gruparea vectorilor similari. Toţi vectorii de date ce au valori asemănătoare vor căpăta o aceeaşi etichetă de apartenenţă, formând un grup. Rezultă astfel o partiţionarea completă a setului de vectori de trăsături asociaţi pixelilor imaginii, ceea ce induce partiţionarea completă a suportului spaţial al imaginii, şi deci segmentarea acesteia (respectând condiţiile (5.1a) şi (5.1b)). Asemănarea cu procesul de segmentare orientată pe regiuni este evidentă. Suplimentar, pentru fiecare grup, este posibilă determinarea unui reprezentant tipic care să aproximeze vectorii de date din grupul respectiv, această abordare fiind fundamentul cuantizării vectoriale, tehnică discutată în cadrul compresiei imaginilor, în secţiunea 10.2.4.

Clustering net

Metodele de clustering iterativ distribuie obiectele (vectorii) într-un număr predefinit de clase, repetând testarea unor condiţii pentru fiecare obiect al mulţimii; în funcţie de

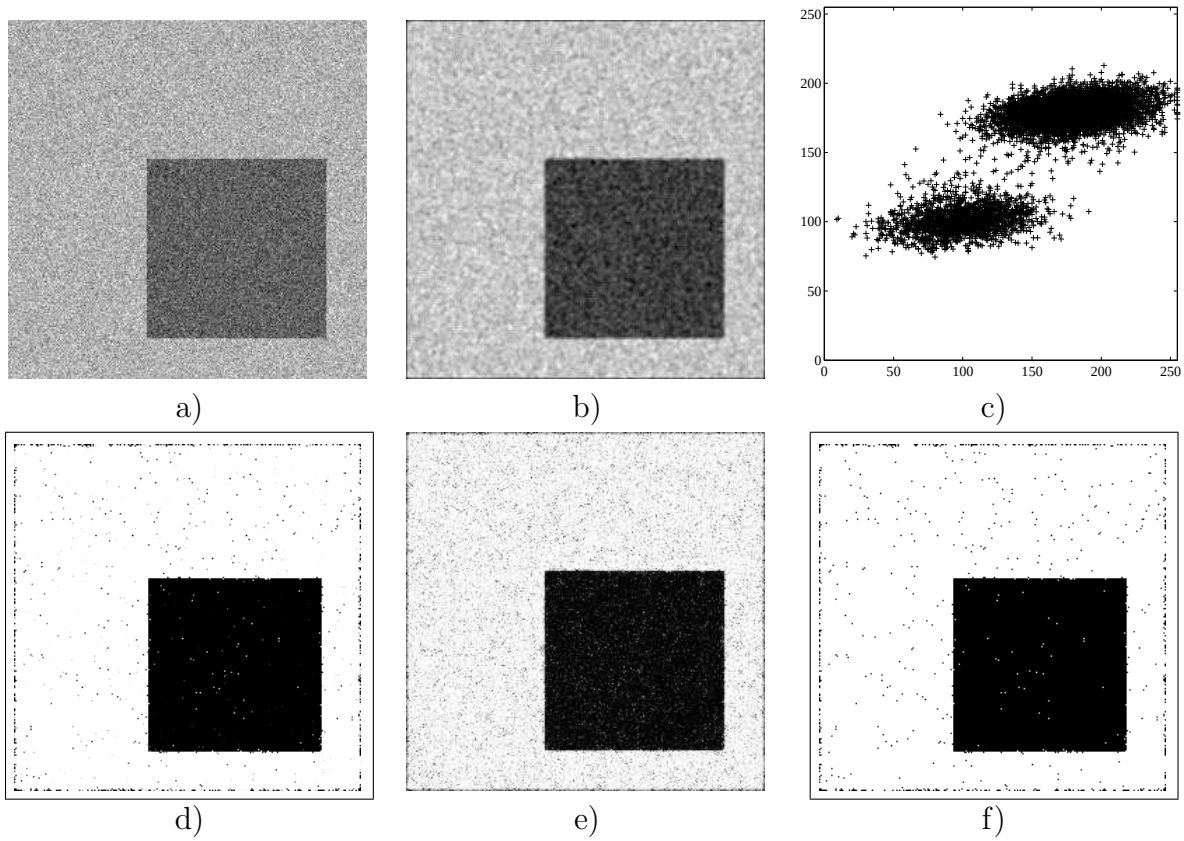


Figura 5.14: *Construirea unui spaţiu al caracteristicilor multi-dimensional: a) imagine originală; b) imagine obţinută ca urmare a unei filtrări de mediere locală; c) reprezentarea pixelilor din imagine în spaţiul caracteristicilor (nivel de gri, nivel de gri mediu) – se observă că în acest spaţiu bidimensional al caracteristicilor apare o evidentă separare a două grupuri de pixeli, ce corespund obiectului de interes şi respectiv fundalului; d) rezultatul binarizării imaginii originale din a) în spaţiul caracteristicilor din c) cu un algoritm de clustering ISODATA; e) imaginea gradului fuzzy de apartenenţă a pixelilor la clasa fundal; f) rezultatul binarizării imaginii originale din a) în spaţiul caracteristicilor din c) cu un algoritm de clustering Fuzzy ISODATA (FCM), cu grade de apartenenţă defuzificate pe baza regulii de apartenenţă maximă (eroarea de segmentare este de* $1,83\%$*).*

îndeplinirea sau nu a respectivelor condiţii, partiţia existentă la un moment dat este declarată corespunzătoare sau, în urma modificării alocării unor unităţi, procedeul de verificare se reia. Se poate considera că algoritmii iterativi fac mai multe treceri prin setul de obiecte de partiţionat, până la obţinerea stabilizării (convergenţei) valorii criteriului ce caracterizează calitatea partiţiei.

Calitatea partiţiei (a clasificării) este măsurată de suma varianţelor claselor ω_j (adică suma distanţelor de la fiecare vector la centrul clasei în care aparţine, ceea ce poate fi interpretat şi ca o eroare de aproximare a vectorilor din clase prin centrul respectivei clase). Deci funcţia criteriu ce trebuie minimizată este

$$J = \sum_{j=1}^{C} J_j = \sum_{j=1}^{C} \sum_{\mathbf{x}_i \in \omega_j} \|\mathbf{x}_i - \mu_j\|^2 = \sum_{j=1}^{C} \sum_{i=1}^{N} u_{ij} \|\mathbf{x}_i - \mu_j\|^2 \tag{5.36}$$

În urma minimizării lui J trebuie determinate valorile μ_j (centrele claselor) şi valorile binare u_{ij}, coeficienţii de apartenenţa ai vectorilor i la clasele j, definiţi de:

$$u_{ij} = \begin{cases} 1, \text{ dacă } \mathbf{x}_i \in \omega_j \\ 0, \text{ dacă } \mathbf{x}_i \notin \omega_j \end{cases} \tag{5.37}$$

Determinarea centrelor claselor se poate face simplu, prin anularea derivatei funcţiei criteriu J în raport cu μ_j:

$$\frac{\partial J}{\partial \mu_j} = 2 \sum_{i=1}^{N} u_{ij} \left(\mu_j - \mathbf{x}_i \right) = 0 \tag{5.38}$$

de unde rezultă că centrele claselor sunt mediile vectorilor ce aparţin acestora:

$$\mu_j = \frac{\sum\limits_{i=1}^{N} u_{ij} \mathbf{x}_i}{\sum\limits_{i=1}^{N} u_{ij}} \tag{5.39}$$

Determinarea coeficienţilor de apartenenţă u_{ij} este însă o problemă de optimizare combinatorială, care nu poate fi rezolvată analitic. Pentru rezolvarea acestei probleme sunt necesare metode iterative. Metoda imediată urmăreşte să determine, pentru fiecare vector al setului, dacă acesta poate fi mutat dintr-o clasă în alta, astfel ca suma varianţelor claselor să scadă. După fiecare asemenea mutare, este necesară actualizarea mediilor claselor între care s-a făcut schimbul. Iteraţiile se repetă până când nici un vector nu mai poate fi mutat. Algoritmul este descris de următoarele etape:

1. se alege o partiţie aleatoare a setului de obiecte (vectori)
2. pentru fiecare vector $\mathbf{x}_i$ din set, dacă nu este unic în clasa sa ω_j, se calculează costul mutării în altă clasă, ω_k, $k \neq j$; acest cost este
$$c_k = \frac{n_k}{n_k + 1} \left\| \mathbf{x}_i - \mu_k \right\|^2 - \frac{n_j}{n_j - 1} \left\| \mathbf{x}_i - \mu_j \right\|^2 \tag{5.40}$$
3. vectorul $\mathbf{x}_i$ este mutat în clasa pentru care costul c_k este minim; se recalculează mediile claselor implicate în schimbare (ω_j şi ω_k)
4. dacă cel puţin un vector a fost mutat între două clase, algoritmul se reia de la pasul 2.

Principalul dezavantaj al acestei abordări este faptul că mediile claselor sunt recalculate după fiecare schimbare ce implică fiecare vector al mulţimii considerate, ceea ce are ca efect un volum mare de calcule. O simplificare a metodei provine din observaţia intuitivă că este normal ca un obiect să fie alocat (să aparţină) clasei de care este cel mai apropiat (în sensul distanţei la media acesteia). Folosind acestă observaţie, realocarea se poate face pentru toate obiectele considerate fără a fi nevoie de recalcularea mediilor claselor pentru fiecare obiect; recalcularea mediilor se va face după fiecare parcurgere completă a mulţimii de obiecte de partiţionat. Acest algoritm este numit "Basic ISODATA" (de la "Iterative Self Organizing Data Analysis Technique" - tehnică iterativă cu auto-organizare de analiză a datelor, apărut prin 1965)", cunoscut şi sub numele de k-means sau C-means – "cele k (sau C) medii"). Algoritmul este descris de următoarele etape:

1. se alege o partiţie aleatoare a setului de obiecte (vectori)
2. pentru fiecare vector $\mathbf{x}_i$ din set, se calulează distanţele sale la mediile tuturor claselor,
$$d_k = \|\mathbf{x}_i - \mu_k\|^2 \tag{5.41}$$
3. în iteraţia următoare, vectorul $\mathbf{x}_i$ va fi mutat în clasa la care distanţa d_k este minimă
4. după parcurgerea completă a setului de vectori, se reactualizează mediile claselor
5. dacă (faţă de iteraţia anterioară) nici un vector nu a fost mutat în altă clasă (sau media nici unei clase nu s-a modificat), algoritmul se încheie; dacă nu, se reia algoritmul de la pasul 2.

Figura 5.14 d) prezintă rezultatul unei binarizări realizate prin clustering ISODATA.

Clustering fuzzy probabilist

O presupunere fundamentală ce a fost utilizată de toţi algoritmii de segmentare pe regiuni prezentaţi anterior (creşterea regiunilor şi diferitele variante de segmentare pe histogramă) este aceea că regiunile extrase formează o partiţie completă a suportului spaţial al imaginii. Aceasta, conform condiţiilor (5.1a) şi (5.1b), înseamnă că regiunile sunt mutual disjuncte, deci nici un punct al imaginii nu poate aparţine simultan la două regiuni. Privită din perspectiva descrierii pixelilor ce formează o regiune oarecare, problema este binară: un pixel aparţine sau nu aparţine regiunii. Această abordare nu permite luarea în considerare a unor puncte din imagine ale căror proprietăţi nu sunt perfect consistente cu proprietăţile impuse regiunii, fie pentru că valorile caracteristice pixelilor respectivi sunt incerte, fie pentru că respectivele valori situează pixelii respectivi, în spaţiul caracteristicilor, între grupurile compacte de puncte ce formează clasele.

Incertitudinea asociată valorilor ce caracterizează punctele imaginii poate avea cauze multiple: cuantizarea valorilor reale ale mărimilor fizice măsurate în scenă, prezenţa zgomotului sau imposibilitatea observatorilor de a deosebi nivele de gri foarte apropiate (de exemplu, în cazul unei cuantizări cu $M = 256$ nivele de gri, diferenţa dintre nivelele de gri 100 şi 101 nu este sesizabilă perceptual). Posibilitatea ca anumite puncte ale imaginii să se situeze simultan în mai multe clase (sau la frontiera acestora) este un caz frecvent întâlnit în imagistica medicală (unde contururile organelor sunt relativ incerte, ca urmare a mişcărilor involuntare ale subiectului în timpul preluării imaginii) sau în imaginile satelitare (unde un teren pe care există pâlcuri de copaci nu poate fi declarat nici pădure şi nici câmp agricol). Soluţia pentru aceste cazuri este relaxarea condiţiei de nesuprapunere a regiunilor şi deci acceptarea faptului că un punct al imaginii poate aparţine unei regiuni într-o măsură mai mare sau mai mică. Aceasta conduce la definirea funcţiei caracteristice a unei regiuni ca o funcţie Lukasiewicz, cu valori în intervalul $[0, 1]$, funcţie ce exprimă gradul în care un pixel aparţine regiunii (sau gradul de apartenenţă a pixelului la regiune) şi la modelarea regiunilor din imagine ca mulţimi nuanţate sau vagi (*fuzzy*).

Mulţimile vagi, introduse de Zadeh în anii '60 se revendică din teoria logicii nuanţate a lui Lukasiewicz, în care propoziţiile nu sunt pe de-a întregul adevărate sau pe de-a întregul false. La modul simplist de interpretare, logica vagă presupune înlocuirea

funcţiilor caracteristice binare de descriere a mulţimilor cu funcţii ce iau valori în domeniul $[0, 1]$. În aceste condiţii, metodele de clustering deja prezentate (aşa cum este metoda ISODATA) capătă noi forme.

Fiecărui vector de trăsături $\mathbf{x}_j$ ataşat unui pixel i se asociază mulţimea de grade de apartenenţă la cele K clase ale partiţiei: $u_{1j}, u_{2j}, \ldots, u_{Kj}$, cu $u_{ij} \in [0, 1]$. Criteriul cantitativ ce exprimă calitatea partiţiei şi care trebuie optimizat este calitatea aproximării vectorilor de trăsături $\mathbf{x}_j$ prin centroizii claselor μ_i, calitate măsurată ca o eroare pătratică.

$$J = \sum_{i=1}^{C} \sum_{j=1}^{N} u_{ij}^m \left\| \mathbf{x}_j - \mu_i \right\|^2 . \tag{5.42}$$

Optimizarea criteriului de calitate a partiţiei se face sub constrângerea ca suma gradelor de apartenenţă a unui punct la toate clasele partiţiei să fie 1 (şi deci punctul să fie partajat între cele K clase ale partiţiei), deci:

$$\sum_{i=1}^{K} u_{ij} = 1, \ \forall j = 1, \ldots, N. \tag{5.43}$$

Această formă matematică a constrângerii, care aminteşte de condiţia de normare a unui câmp de probabilităţi, impune numele de "clustering probabilist"; trebuie totuşi avut în vedere că nimic altceva în afara acestei asemănări nu face apel la teoria probabilităţilor. Cele N constrângeri din (5.43) se vor încorpora prin metoda multiplicatorilor lui Lagrange criteriului J (5.42) de optimizat, rezultând o nouă funcţie, $\tilde{J}$, în necunoscutele u_{ij} şi μ_i:

$$\tilde{J} = \sum_{i=1}^{K} \sum_{j=1}^{N} u_{ij}^m \left\| \mathbf{x}_j - \mu_i \right\|^2 - \sum_{j=1}^{N} \lambda_j \left(\sum_{i=1}^{K} u_{ij} - 1 \right) . \tag{5.44}$$

Derivatele parţiale ale funcţiei $\tilde{J}$, dupá necunoscutele μ_s şi u_{st} oarecari, dar fixate, sunt:

$$\frac{\delta \tilde{J}}{\delta \mu_s} = 2 \sum_{j=1}^{N} u_{ij}^m \left(\mathbf{x}_j - \mu_s \right) = 0 \tag{5.45}$$

$$\frac{\delta \tilde{J}}{\delta u_{st}} = m u_{st}^{m-1} \left(\mathbf{x}_j - \mu_s \right)^2 - \lambda_t = 0. \tag{5.46}$$

Ecuaţia (5.45) permite determinarea centroizilor (prototipurilor, centrelor) claselor ca:

$$\mu_i = \frac{\sum\limits_{j=1}^{N} u_{ij}^m \mathbf{x}_j}{\sum\limits_{j=1}^{N} u_{ij}^m}. \tag{5.47}$$

Ecuaţia (5.46) conduce la exprimarea gradelor de apartenenţă u_{st} a vectorilor la clase ca:

$$u_{st} = \left(\frac{\lambda_t}{m(\mathbf{x}_t - \mu_s)^2} \right)^{\frac{1}{m-1}} . \tag{5.48}$$

Înlocuind expresiile gradelor de apartenenţă din (5.48) în ecuaţia ce exprimă constrângerea probabilistă (5.43), se poate obţine o expresie pentru multiplicatorii Langrage, λ_t:

$$\left(\frac{\lambda_t}{m}\right)^{\frac{1}{m-1}} = \frac{1}{\sum_{i=1}^{K}\left(\frac{1}{(\mathbf{x}_t-\mu_i)^2}\right)^{\frac{1}{m-1}}}. \tag{5.49}$$

În fine, înlocuind valorile multiplicatorilor Lagrange daţi de (5.49) în expresia iniţială a gradelor de apartenenţă (5.46), obţinem expresia finală de calcul a acestora:

$$u_{ij} = \frac{\left(\frac{1}{(\mathbf{x}_t-\mu_i)^2}\right)^{\frac{1}{m-1}}}{\sum_{s=1}^{K}\left(\frac{1}{(\mathbf{x}_t-\mu_s)^2}\right)^{\frac{1}{m-1}}}. \tag{5.50}$$

Soluţia finală căutată (centroizii celor K clase şi gradele de apartenenţă a vectorilor de trăsături la acestea) este deci formată din sistemul de ecuaţii (5.47) şi (5.50). Rezolvarea acestui sistem este iterativă, soluţiile nefiind analitice. Algoritmul de clustering astfel obţinut este *"Fuzzy ISODATA"* (sau Fuzzy C-Means, FCM) şi a fost propus de Bezdeck la începutul anilor '80. Etapele acestui algoritm sunt:

1. Se iniţializează centroizii claselor μ_i cu valori aleatoare, sau, în ipoteza existenţei unor cunoştinţe apriorice care să permită o asemenea iniţializare, cu valori relativ apropiate de valorile corecte.
2. Se calculează gradele de apartenenţă ale vectorilor la clase, prin (5.50).
3. Se recalculează centrele claselor prin (5.47).
4. Se repetă paşii 2 şi 3 atâta timp cât modificările ce intervin în valorile centroizilor sau ale gradelor de apartenenţă sunt importante.

Parametrul m poartă numele de grad de fuzificare al partiţiei (în mod clasic valoarea sa este $m = 2$) şi controlează distribuţia gradelor de apartenenţă a vectorilor de date între cele K clase ale partiţiei. Dacă $m \to \infty$, termenul cel mai important al sumei de la numitorul expresiei din (5.50) va fi cel ce va corespunde clasei al cărei centroid este cel mai apropiat de vectorul $\mathbf{x}_j$ dat. Deci se obţine practic o partiţionare netă (de tip ISODATA), în care vectorul $\mathbf{x}_j$ va avea grad de apartenenţă aproape unitar la clasa de care este cel mai apropiat, şi grade de apartenenţă aproape nule la celelalte clase ale partiţiei. Dacă $m = 2$, se obţine cazul "cel mai vag", pentru care vectorii $\mathbf{x}_j$ sunt maxim partajaţi între toate clasele. Complexitatea de calcul a algoritmului FCM este mult mai mare decât cea a variantei sale nete şi, în general, numărul de iteraţii necesare pentru atingerea convergenţei este mai mare.

Folosirea unui algoritm de clustering FCM garantează obţinerea unor centroizi (prototipuri) mult mai credibile pentru clasele partiţiei şi permite identificare vectorilor de date a căror apartenenţă este incertă (caracterizaţi de lipsa unei valori u_{ij} dominante), caracteristică ce poate fi utilă în determinarea unor regiuni segmentate uniforme. După cum se observă din figura 5.14 e), rezultatul primar al algoritmului de clustering este o

imagine în care fiecărui pixel îi este ataşat gradul de apartenenţă la una dintre cele K clase ale partiţiei. Imaginea clasei corespunzătoare se obţine printr-o etapă suplimentară numită de defuzificare a partiţiei create prin clustering: fiecare vector $\mathbf{x}_j$ se consideră ca făcând parte din regiunea ce corespunde clasei la care are gradul de apartenenţă maxim.

5.3 Concluzii

Segmentarea (şi etichetarea imaginilor binare) sunt componente esenţiale ale oricărui sistem de analiză a imaginilor. Calitatea segmentării este determinantă pentru performanţa întregului sistem.

Metodele prezentate în acest capitol sunt cu adevărat fundamentale, regăsindu-se în forme modificate în orice tehnică de segmentare alternativă.

Se mai pot avea în vedere probleme ce nu au fost discutate, precum compensarea zgomotului ca parte a algoritmilor de segmentare, post-filtrarea imaginilor segmentate (de etichete), încorporarea constrângerilor spaţiale în algoritmii de segmentare în spaţiul caracteristicilor.